MATRIX 25-2 컨퍼런스 · 2팀 · 개선 노트북 해설

Animal Shelter v2 노트북 설명 보고서

문제점 7개를 반영한 Animal_Shelter_Analytics_v2.ipynb의 구성, 변경 내용, 결과

대상 파일 | Animal_Shelter_Analytics_v2.ipynb · figures_v2/ (그림 7장)
작성일 | 2026년 9월 25일 · 함께 보기: Animal_Shelter_프로젝트_분석보고서.pdf

한 줄 요약

분석 보고서에서 지적한 문제 7개를 모두 고친 새 노트북입니다. 고친 뒤 다시 계산해 보니 **2단계 모델의 우위는 사라졌고**(최종 전략: 직접모델), **개·고양이 기준 실제 안락사 예측 성능은 PR-AUC 0.33**(무작위 기준선의 약 10배)이었습니다. 운영 메시지는 **"입소 동물의 25%를 검토하면 안락사의 82%를 미리 포착"**으로 바뀝니다.

목차

1	한눈에 보기	무엇이 바뀌었고, 결론이 어떻게 달라졌는가
2	노트북 구성과 실행 방법	13개 섹션 지도 · 실행 환경 · 산출물
3	문제별 해결 내용	문제 1~7: 기존 방식 → 개선 방식 → 결과
4	섹션별 결과 상세	병합 · 변수 실험 · 입양 · 안락사 · 불균형 · 시간 검증
5	기존 vs 개선 비교	핵심 수치 전후 비교표
6	발표자료 수정 가이드	슬라이드별로 무엇을 바꿔야 하는가
7	남은 한계	이번 개선으로도 해결되지 않은 점
부록	새로 등장한 개념	merge_asof · Pipeline · OOF · SMOTENC · SHAP 읽는 법 등

SECTION 1

한눈에 보기

1.1 무엇이 바뀌었나

문제	기존	v2 노트북
1 전략 비교	서로 다른 집단에서 PR-AUC 비교	같은 test 전체 + 동물 ID 교차검증으로 선택
2 안락사 대상	야생동물 포함 전체	**개·고양이** (야생동물은 규칙 기준선과 비교)
3 병합	방문 순번 짝짓기	**merge_asof** (입소 이후 첫 퇴소) + 중복 제거
4 이름 변수	has_name	**has_original_name** (보호소 부여 이름 제외)
5 불균형 검증	일반 K-Fold · 학습 데이터 임곗값 · SMOTE	**StratifiedGroupKFold · OOF 임곗값 · SMOTENC**
6 재현성	절대경로 · 입양 모델 코드 없음	상대경로 · 입양 튜닝·SHAP 통합 · 그림 자동 저장
7 기타	분할 전 그룹화 · 공통 나이 구간 · 검증 없는 계절	파이프라인 · **종별 생애단계 · 품종군** · 계절 실험 · **시간 검증**

1.2 결론이 어떻게 달라졌나

항목	기존 결론	v2 결론
최종 안락사 전략	2단계 (PR-AUC 0.777 > 0.746)	**직접모델** (CV에서 2단계가 0.011 낮음, 우위 없음)
안락사 성능	PR-AUC 0.777 · Recall 0.817	**PR-AUC 0.332** · ROC-AUC 0.870 (개·고양이, 기준선 0.032)
운영 해석	안락사 위험군의 82%를 식별	입소 동물 **25%**를 검토하면 안락사의 **82%** 포함 (10건 중 1건 적중)
이름 변수	예측 핵심 변수	보호소 부여 이름은 **누수** → 원래 이름만 사용
계절 변수	포함	**제외** (효과가 폴드 변동보다 작음)
미래 적용	검증 없음	안락사 ROC-AUC 0.865 유지 · **연도별 Recall 0.73~0.86 변동**

핵심 메시지

성능 숫자는 **낮아졌지만**, 그 대신 **보호소가 실제로 개입할 수 있는 동물**에 대해 **새 데이터에서도 유지되는** 수치가 되었습니다. 발표에서는 "야생동물을 분리하고 누수를 제거한 뒤에도 무작위 대비 10배의 선별력이 있다"로 설명하는 것이 심사 질문에 가장 강한 답이 됩니다.

SECTION 2

노트북 구성과 실행 방법

Animal_Shelter_Analytics_v2.ipynb는 48개 셀, 13개 섹션으로 구성됩니다.

§	섹션	하는 일	관련 문제
0	개요	문제 7개와 해결 섹션 대응표	-
1	환경 설정	라이브러리, 한글 폰트, 그림 저장 함수	-
2	데이터 불러오기	같은 폴더의 zip에서 CSV를 바로 읽음 (상대경로)	6
3	입·퇴소 병합	중복 제거 → merge_asof → 기존 방식과 비교표	3
4	타깃 정의	5개 범주 → target_adoption, target_euthanasia	-
5	전처리 · 특성공학	이름 3종, 종별 생애단계, 품종군, 혼종 정의 보완	4, 7
6	EDA	안락사 구성(동물 종류·사유), 이름 유형별 결과, 생애단계	2, 4
7	분할 · 파이프라인	그룹 분할, 개·고양이 부분집합, ColumnTransformer, 평가 함수	2, 7
8	변수 선택 실험	이름 변수 3종 · 계절 포함 여부를 CV로 비교 → 최종 특성 결정	4, 7
9	입양 모델	LR · RF · LGBM 비교 → LGBM 튜닝 → SHAP	6
10	안락사 모델	전체 동물 vs 개·고양이, 직접 vs 2단계 공정 비교(CV + test)	1, 2
11	불균형 대응	가중치 없음 · balanced · SMOTENC를 그룹 CV + OOF 임곗값으로 비교, 안락사 SHAP	5
12	시간 기준 검증	~2018 학습 → 2019~2021 평가, 연도별 성능	7
13	최종 요약	기존 vs 개선 표, 결론, 남은 한계	-

2.1 실행 방법

- 노트북을 **반려동물 데이터셋.zip과 같은 폴더**에 두고 위에서부터 순서대로 실행합니다. 압축을 풀 필요가 없습니다.
- 필요 패키지: pandas, scikit-learn 1.2 이상, lightgbm, imbalanced-learn, shap (Anaconda 기준 모두 설치되어 있었음)
- 실행 시간: 약 **29분** (튜닝 12회×3폴드, 교차검증 다수 포함). 튜닝 결과는 random_state=42로 고정되어 다시 실행해도 같은 결과가 나옵니다.
- Windows에서 joblib 코어 탐지 오류가 나는 환경을 위해 첫 셀에 **LOKY_MAX_CPU_COUNT**를 설정했습니다.

2.2 산출물

- **figures_v2/** 폴더에 그림 7장 자동 저장: 01 안락사 구성·이름 유형 · 02 종별 생애단계 · 03 입양 SHAP · 04 안락사 PR 곡선 · 05 혼동행렬 · 06 안락사 SHAP · 07 연도별 결과 구성 (이 보고서의 그림 1~7)

기존 파일(Final.ipynb, X_train.csv 등)은 수정하지 않았습니다. v2는 CSV를 따로 저장하지 않고 원본 zip에서 매번 새로 만듭니다.

SECTION 3

문제별 해결 내용

분석 보고서 7장의 문제 번호를 그대로 사용했습니다.

문제 1 직접모델 vs 2단계 비교 기준 통일 (§10) 해결

기존 방식	2단계 모델은 **비입양 동물만**(안락사 12.5%), 직접모델은 **전체**(6.9%)로 평가 → PR-AUC 0.777 vs 0.746을 비교해 2단계 채택
개선 방식	① 두 전략 모두 **같은 대상(개·고양이 전체)**, **같은 점수 형태**로 평가: 직접 = P(안락사), 2단계 = (1-P(입양)) × P(안락사|비입양) ② **전략 선택은 동물 ID 기준 5-fold CV**로 하고 test는 확인용으로만 사용. 각 폴드 안에서 입양·직접·2단계 모델을 모두 학습 폴드로만 학습 ③ 차이가 폴드 표준편차보다 작으면 단순한 직접모델을 선택하는 **규칙을 미리 정함**
결과	CV: 2단계가 평균 **0.011 낮음** (표준편차 0.011) → **직접모델 채택**. test: 직접 0.332 vs 2단계 0.302. 참고로 기존처럼 비입양 동물만으로 평가하면 2단계가 0.408로 더 좋아 보이는 **착시가 그대로 재현**됨

```
for tr, va in cv_splitter(5).split(Xtr, ye_tr, groups_dc):
    d  = make_model("LGBM", ...).fit(Xtr.iloc[tr], ye_tr.iloc[tr])            # 직접
    a  = make_model("LGBM", ..., **BEST_ADOPT_PARAMS).fit(..., ya_tr.iloc[tr]) # 입양
    s2 = make_model("LGBM", ...).fit(비입양 학습 행만)                          # 2단계
    oof_direct[va] = d.predict_proba(Xtr.iloc[va])[:, 1]
    oof_pipe[va]   = (1 - a.predict_proba(...)[:, 1]) * s2.predict_proba(...)[:, 1]
```

문제 2 안락사 모델 대상을 개·고양이로 분리 (§6, §10-1) 해결

기존 방식	야생동물을 포함한 전체 동물로 학습·평가. 안락사의 절반 이상이 야생동물이라 "야생동물이면 안락사"라는 쉬운 규칙으로 점수가 부풀려짐
개선 방식	① EDA에서 안락사 구성과 사유를 동물 종류별로 분해 ② 전체 동물 모델의 성능을 Other / 개·고양이로 나눠 보고 ③ "Other 또는 Wildlife" 규칙을 기준선으로 비교 ④ 이후 모든 안락사 분석을 **개·고양이**로 수행
결과	안락사의 **55.7%가 Other**, 그 사유의 79%가 광견병 위험. 전체 모델 PR-AUC 0.73 = Other 0.91 + 개·고양이 **0.33**. 규칙 하나로도 0.39. 개·고양이 전용 모델 0.332 → 이것이 **실제 개입 대상에 대한 성능**

문제 3 입·퇴소 병합을 merge_asof로 교체 (§3) 해결

기존 방식	Animal ID + 방문 순번(visit_seq)으로 짝지음 → 입·퇴소 횟수가 다른 동물에서 순번이 밀려 **체류기간 음수 694행**
개선 방식	① 완전 중복 행 제거 (입소 19, 퇴소 17) ② **입소 시각 이후 가장 가까운 퇴소**를 연결 (merge_asof, direction=forward) ③ 두 입소가 같은 퇴소에 붙으면 최근 입소만 유지 ④ 기존 방식과 나란히 비교하는 표 출력
결과	체류기간 음수 **694행 → 0행**. 두 방식 모두에 있는 입소 중 **167건**의 연결 퇴소가 바뀌었고, 그중 **58건**은 결과 유형(타깃)이 달라짐

```
df = pd.merge_asof(i, o, left_on="DateTime_intake", right_on="DateTime_outcome",
                   by="Animal ID", direction="forward", suffixes=("_intake", "_outcome"))
df = df.dropna(subset=["DateTime_outcome"])
df = df.sort_values("DateTime_intake").drop_duplicates(["Animal ID", "DateTime_outcome"], keep="last")
```

문제 4 이름 변수 누수 제거 (§5, §6, §8) 해결

기존 방식	이름이 있으면 1인 has_name을 사용. 보호소가 나중에 붙인 이름(*로 시작)도 '이름 있음'으로 취급
개선 방식	① 이름을 **없음 / 보호소 부여(*) / 원래 이름** 3종으로 구분해 결과 비교 ② has_name · has_original_name · 이름 제외 세 가지를 CV로 비교 ③ 최종 모델에는 **has_original_name** 사용
결과	보호소 부여 이름: 입양률 **66.7%**, 안락사율 **1.3%** — 원래 이름(45.5%, 2.2%)보다도 결과가 좋음 → 입양 절차가 진행되는 동물에게 이름이 붙는다는 증거. has_name을 쓰면 안락사 CV PR-AUC가 0.339 → 0.390으로 **0.05 부풀려짐**

문제 5 불균형 실험의 검증 방식 수정 (§11) 해결

기존 방식	RepeatedStratifiedKFold(같은 동물이 폴드에 섞임) · 임곗값을 **학습 데이터**로 결정(0.499) · 원-핫 데이터에 SMOTE
개선 방식	① **StratifiedGroupKFold**(동물 ID 단위) ② 임곗값은 **OOF(검증 폴드) 예측**에서 Recall ≥ 0.8을 만족하는 값 중 Precision 최대로 결정 → test에 그대로 적용 ③ 원본 범주형에 **SMOTENC**를 먼저 적용한 뒤 원-핫 (imblearn Pipeline, 학습 폴드 안에서만)
결과	SMOTENC CV PR-AUC 0.285로 최하 → 사용 안 함. 가중치 없음 0.343 ≒ balanced 0.340. OOF 임곗값 0.379를 test에 적용한 결과 **Recall 0.815** → 임곗값이 새 데이터에서도 유지됨을 확인

```
strategies["SMOTENC (폴드 내부)"] = ImbPipeline([
    ("smote", SMOTENC(categorical_features=smote_cat_idx, random_state=SEED)),
    ("prep",  make_prep(FINAL_CAT, FINAL_NUM)),        # SMOTENC 다음에 원-핫
    ("model", LGBMClassifier(random_state=SEED, verbose=-1))])
oof, ap = oof_predict(pipe, Xtr, ye_tr, groups_dc)      # StratifiedGroupKFold
thr = threshold_for_recall(ye_tr, oof, 0.8)             # OOF로 임곗값 결정
```

문제 6 재현성 확보 (§2, §9) 해결

기존 방식	개인 PC 절대경로 · 발표의 입양 모델(튜닝·SHAP) 코드가 폴더에 없음 · 저장한다던 그림 파일 없음 · 슬라이드마다 수치 출처가 다름
개선 방식	① zip을 **상대경로**로 바로 읽음 ② 입양 모델 **LR·RF·LGBM 비교 → RandomizedSearchCV 튜닝(그룹 CV) → SHAP**을 한 노트북에 통합 ③ 모든 그림을 figures_v2/에 저장 ④ 모든 표에 평가 대상(CV / test / 부분집합)을 열 이름으로 명시
결과	튜닝 LightGBM: ROC-AUC **0.783**, 비입양 Recall 0.664 · Precision 0.770. 한 번의 실행으로 발표에 필요한 모든 수치와 그림이 만들어짐

문제 7	기타 개선 (§5, §7, §8, §12)	해결
기존 방식	상위 15개 품종·색상을 분할 전 전체 데이터로 결정 · 개·고양이 공통 나이 구간 · 계절 변수 검증 없음 · 시간 기준 검증 없음	
개선 방식	① OneHotEncoder(max_categories=16)를 **파이프라인 안에서 train으로만 학습** ② **종별 생애단계**: 개 1·3·7세, 고양이 1·6·10세 기준 / **품종군**: 불리계·소형·테리어·목양견 등 8개 + 고양이 털 길이 ③ 혼종 정의에 'A/B' 형태 추가 ④ 계절 제외 실험 ⑤ ~2018 학습 → 2019~2021 평가	
결과	계절 효과 +0.0003 / -0.0005 (표준편차보다 작음) → **제외**. 시간 검증에서 안락사 ROC-AUC **0.865 유지**, 입양 ROC-AUC 0.742로 소폭 하락, 같은 임곗값의 Recall이 **연도별 0.73~0.86으로 변동**	

SECTION 4

섹션별 결과 상세

노트북 출력 결과를 그대로 옮기고 해석을 붙였습니다.

4.1 병합 비교 (§3)

	기존 (visit_seq)	개선 (merge_asof)
병합 행 수	123,543	122,960
체류기간 < 0 행	694	**0**
체류기간 > 365일 행	304	307

행 수가 줄어든 것은 퇴소 기록이 없는 입소(아직 보호 중)와, 중간 퇴소 기록이 빠져 같은 퇴소에 붙은 입소를 정리했기 때문입니다.

4.2 EDA — 안락사 구성과 이름 (§6)

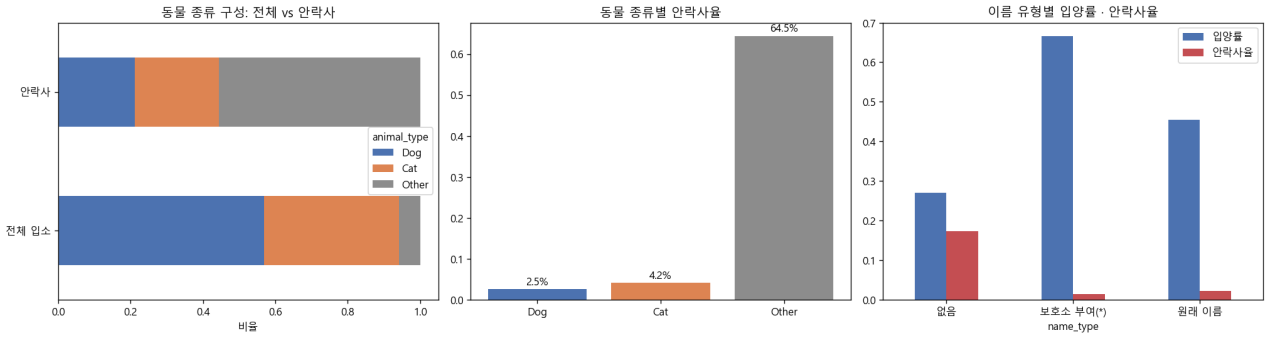


그림 1. 왼쪽: 전체 입소 중 6%인 Other가 안락사의 56%를 차지 · 가운데: 종류별 안락사율(개 2.5%, 고양이 4.2%, Other 64.5%) · 오른쪽: 보호소가 붙인 이름(*)의 입양률이 가장 높음

동물	안락사 사유 상위 3개
Other	광견병 위험 79% · 고통 16% · 의료 4%
개	고통 48% · **공격성 30%** · 행동 9%
고양이	고통 87% · 동물병원 5% · 광견병 위험 4%

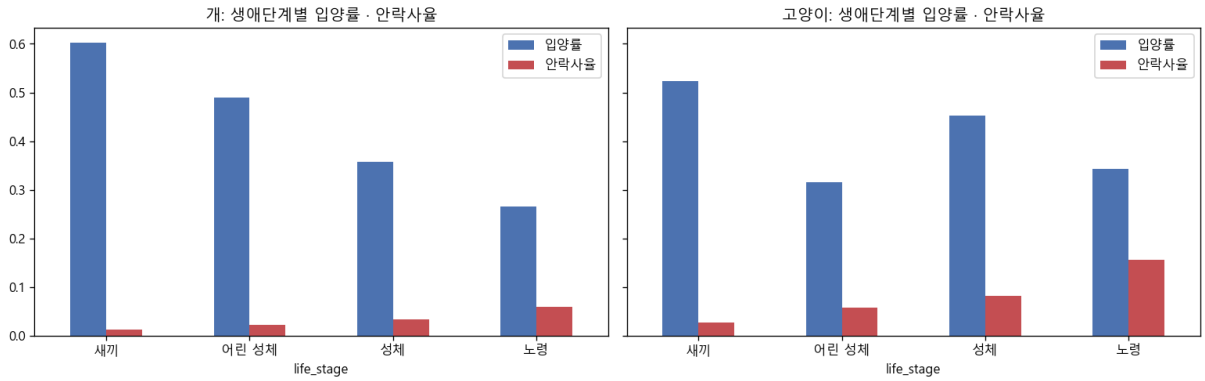


그림 2. 종별 생애단계(개 1·3·7세, 고양이 1·6·10세). 두 종 모두 노령으로 갈수록 입양률이 떨어지고 안락사율이 오름

4.3 변수 선택 실험 (§8, 개·고양이 train, 동물 ID 5-fold CV)

설정	입양 PR-AUC	안락사 PR-AUC	해석
기준: has_original_name + 계절	0.734 ± 0.003	0.339 ± 0.019	-
has_name (기존 변수)	0.743 ± 0.003	**0.390** ± 0.024	보호소 부여 이름이 결과를 누설
이름 변수 제외	0.709 ± 0.003	0.319 ± 0.017	원래 이름은 유효한 신호
계절 제외	0.734 ± 0.004	0.340 ± 0.018	차이 없음 → **계절 제외**

최종 특성 14개: animal_type, sex, sterilized_status, Intake Type, Intake Condition, breed_group, life_stage, Breed_intake(상위 15), Color_intake(상위 15), age_days, intake_month, is_mixed_breed, is_multicolor, has_original_name

4.4 입양 모델 (§9, 개·고양이 test 23,237건)

모델	ROC-AUC	PR-AUC	Accuracy	비입양 Recall	비입양 Precision
Logistic Regression	0.717	0.641	0.659	0.599	0.717
Random Forest	0.773	0.722	0.705	0.676	0.748
LightGBM (기본)	0.776	0.726	0.709	0.650	0.771
LightGBM (튜닝)	**0.783**	**0.740**	**0.714**	0.664	0.770

튜닝 결과: num_leaves 127, n_estimators 400, learning_rate 0.05, min_child_samples 10, reg_lambda 1 (CV PR-AUC 0.744). 발표의 비입양 Recall 0.692 / Precision 0.797보다 약간 낮은 것은 야생동물을 빼고 누수 변수를 바꿨기 때문으로, 더 보수적이지만 현실적인 수치입니다.

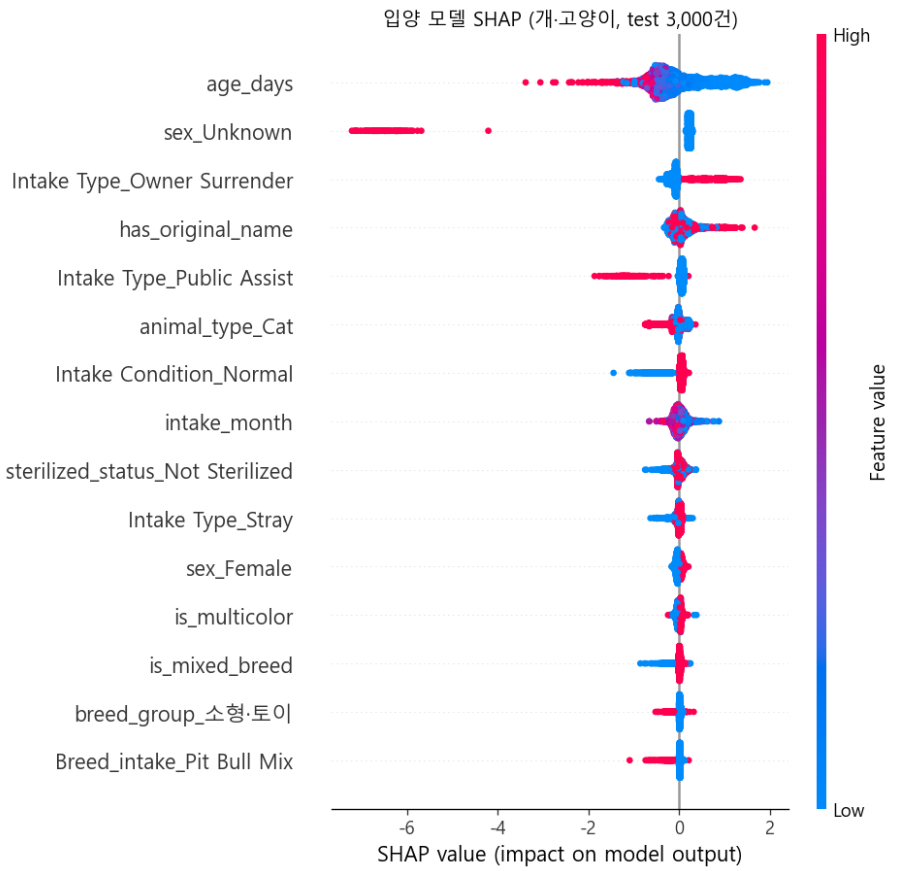


그림 3. 입양 모델 SHAP. 점 하나가 동물 한 마리, 가로축은 입양 확률(로그오즈)에 대한 기여, 색은 변수 값(빨강=높음)

- **나이**: 값이 높을수록(빨강) 왼쪽 → 고령일수록 입양 확률 감소
- **성별 미확인**: 해당하면 크게 감소 — 입소 시 기본 정보가 부족한 동물(부상·야생 상태 등)일 가능성
- **소유자 인계** 증가, **Public Assist**(주인 찾기 목적의 입소) 감소, **원래 이름** 있으면 증가
- 모든 해석은 **연관성**이며 인과가 아닙니다 (부록 참고)

4.5 안락사: 전체 동물 vs 개·고양이 (§10-1)

평가 대상	모델	안락사 비율	PR-AUC	ROC-AUC
전체 동물 test	전체 동물 LGBM	6.7%	0.732	0.937
전체 동물 test	규칙: Other 또는 Wildlife	6.7%	0.387	0.767
Other만	전체 동물 LGBM	64.1%	0.909	0.902
개·고양이만	전체 동물 LGBM	3.2%	**0.329**	0.869
개·고양이만	개·고양이 전용 LGBM	3.2%	**0.332**	0.870

4.6 안락사: 직접 vs 2단계 공정 비교 (§10-2)

교차검증 (전략 선택용)

폴드	1	2	3	4	5	평균
직접 PR-AUC	0.341	0.367	0.338	0.311	0.342	0.340
2단계 PR-AUC	0.331	0.346	0.327	0.319	0.324	0.329
차이 (2단계-직접)	-0.010	-0.021	-0.012	+0.008	-0.018	**-0.011 ± 0.011**

test 확인 (개·고양이 test 전체, 안락사 3.17%)

모델	전략	PR-AUC	ROC-AUC	Precision @Recall 0.8	PR-AUC (비입양만·참고)
Logistic Reg.	직접	0.259	0.841	0.082	0.324
Logistic Reg.	2단계	0.253	0.831	0.078	0.328
Random Forest	직접	0.248	0.847	0.091	0.327
Random Forest	2단계	0.290	0.857	0.091	0.351
LightGBM	**직접**	**0.332**	**0.870**	**0.108**	0.399
LightGBM	2단계	0.302	0.864	0.098	**0.408**

마지막 열은 기존 노트북 방식(2단계를 비입양 동물만으로 평가)입니다. 이 열만 보면 2단계가 이기는 것처럼 보입니다.

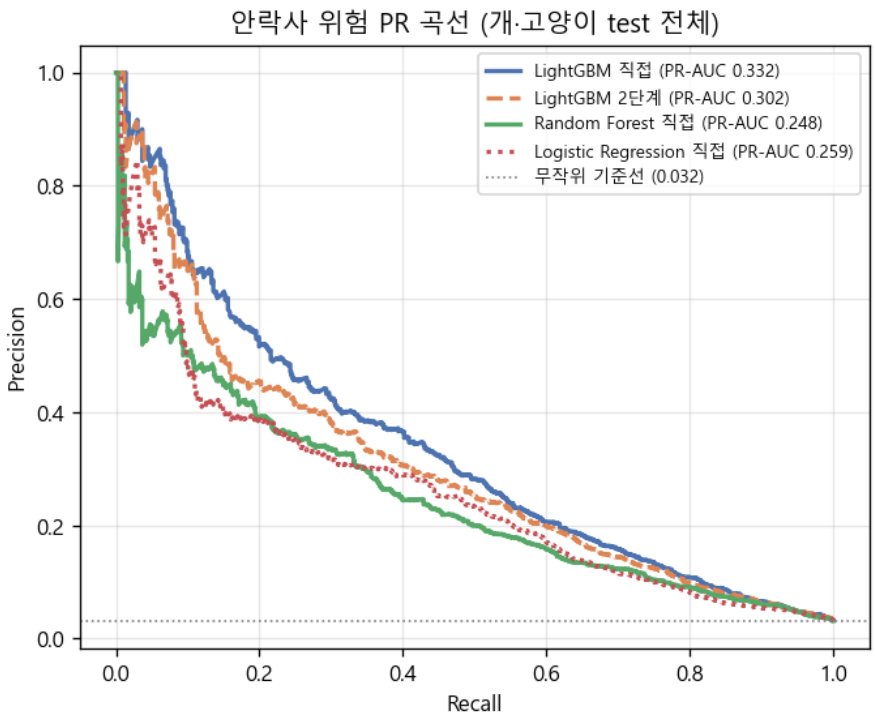
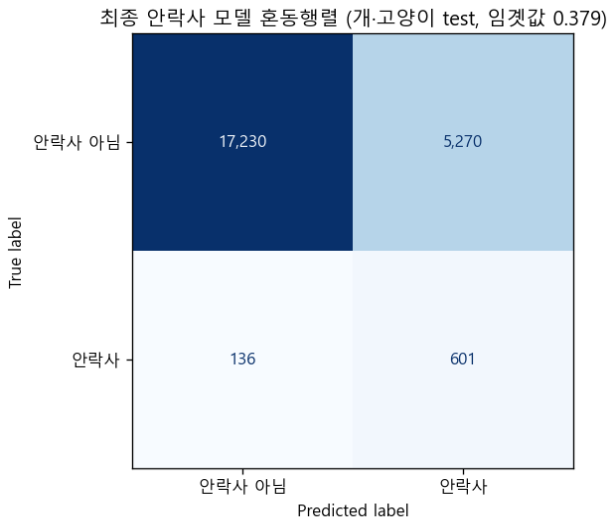


그림 4. 안락사 PR 곡선. 회색 점선이 무작위 기준선(0.032). LightGBM 직접모델이 거의 모든 구간에서 가장 위

4.7 불균형 대응 (§11, LightGBM 직접모델)

전략	CV PR-AUC	OOF 임곗값	test PR-AUC	test Recall / Precision (OOF 임곗값)	test Recall / Precision (0.5)
가중치 없음	0.343 ± 0.015	0.021	0.321	0.814 / 0.101	0.098 / 0.673
class_weight=balanced	0.340 ± 0.018	0.379	**0.332**	**0.815 / 0.102**	0.729 / 0.144
SMOTENC (폴드 내부)	0.285 ± 0.013	0.209	0.263	0.805 / 0.079	0.570 / 0.176

- 가중치 없음과 balanced는 순위 성능(PR-AUC)이 같고, **확률의 크기만 다릅니다**. 그래서 0.5 기준 Recall은 0.10 vs 0.73으로 크게 차이 나지만, OOF로 임곗값을 맞추면 둘 다 0.81이 됩니다.
- → **임곗값을 제대로 정하면 class_weight 여부는 중요하지 않습니다.** 중요한 것은 임곗값을 검증 데이터로 정하는 절차입니다.



혼동행렬 읽기

개·고양이 test 23,237마리 중 모델이
5,871마리(25.3%)를 고위험으로 표시했습니다.

- 실제 안락사 737건 중 **601건 포착** (Recall 0.815)
- 표시된 동물 중 실제 안락사 10.2% (Precision)
- 놓친 안락사 136건

> "입소 동물의 4분의 1을 집중 관리 대상으로 두면 안락사의 5분의 4가 그 안에 있다." → 자동 판정이 아닌 **스크리닝 도구**로 쓰는 것이 맞습니다.

그림 5. 최종 안락사 모델 혼동행렬 (임곗값 0.379)

4.8 안락사 모델 해석 (§11-1)

순위	변수	방향	해석
1	has_original_name	있으면 위험↓	주인이 있던 동물일수록 안락사가 적음
2	age_days	높으면 위험↑	고령일수록 위험
3	Intake Condition = Normal	정상이면 위험↓	부상·질병 동물이 고위험 (사유 '고통'과 일치)
4	Intake Type = Stray	해당하면 위험↓	소유자 인계·안락사 요청 입소가 상대적 고위험
5~6	품종군 소형·토이 / 불리계	소형↓ / 불리계↑	개 안락사 사유의 30%가 공격성과 관련된 연관성 — **인과 아님**

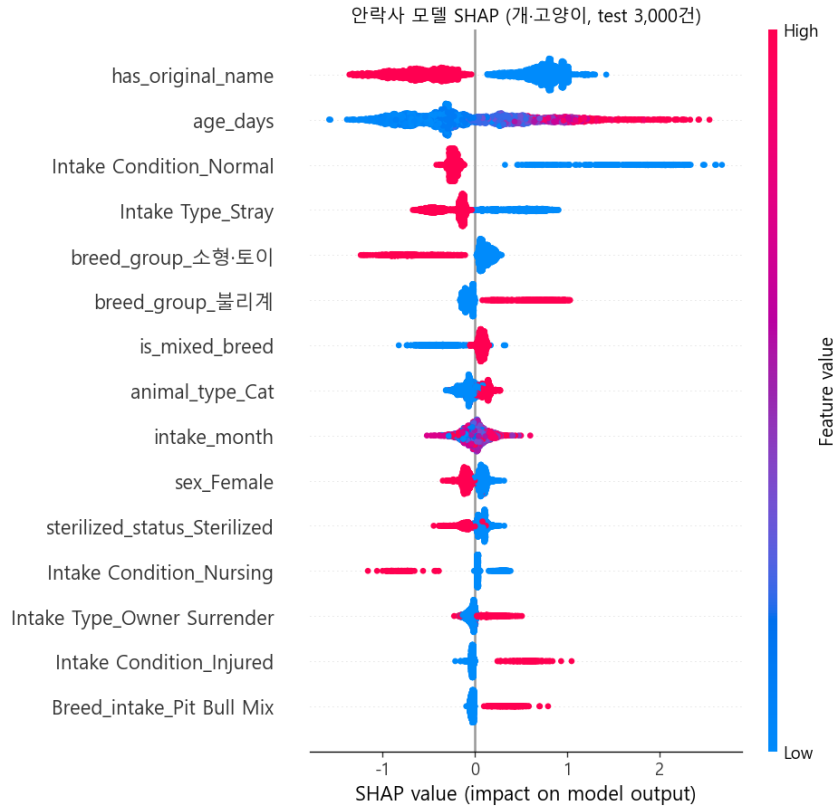


그림 6. 안락사 모델 SHAP (오른쪽으로 갈수록 안락사 위험 증가)

4.9 시간 기준 검증 (§12, ~2018 학습 → 2019~2021 평가)

평가 기간	행 수	입양 ROC-AUC	안락사율	안락사 PR-AUC	안락사 ROC-AUC	Recall @0.379
2019~2021 전체	26,267	0.742	1.89%	0.190	0.865	0.791
2019	17,369	0.746	1.55%	0.167	0.850	**0.726**
2020	8,256	0.732	2.56%	0.218	0.874	**0.858**
2021 (1~3월)	642	0.758	2.49%	0.364	0.945	1.000
(참고) 무작위 분할 test	23,237	0.783	3.17%	0.332	0.870	0.815

- **순위 능력(ROC-AUC)은 미래에도 유지**됩니다 (안락사 0.865, 입양 0.742).
- PR-AUC 하락(0.33 → 0.19)은 모델이 나빠져서가 아니라 **안락사율 자체가 3.2% → 1.9%로 줄었기 때문**입니다. 기준선 대비 배수는 약 10배로 같습니다.
- 같은 임곗값에서 Recall이 **2019년 0.73, 2020년 0.86**으로 흔들립니다 → 발표의 "월별 재평가" 원칙이 실제로 필요하다는 근거입니다.
- 2021년은 642건뿐이고 추출 시점에 아직 보호 중인 동물이 빠져 있어 해석하지 않습니다.

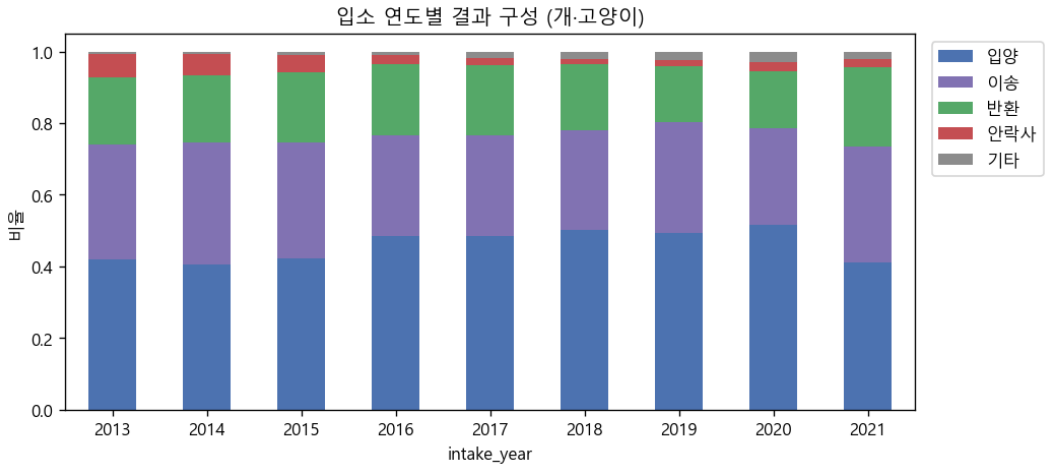


그림 7. 입소 연도별 결과 구성 (개·고양이). 2020년 이후 구성 변화가 보임

SECTION 5

기존 vs 개선 비교

항목	기존 (Final.ipynb)	개선 (v2)
병합 · 체류기간 음수 행	694행	**0행**
타깃이 바뀐 기록	-	58건 교정
안락사 평가 대상	전체 동물 (야생동물 포함)	개·고양이 (야생동물은 규칙으로 분리)
전략 비교 기준	서로 다른 집단 (6.9% vs 12.5%)	같은 test 전체 + 동물 ID CV
안락사 PR-AUC · LGBM 직접	0.746 (전체 동물)	0.332 (개·고양이)
안락사 PR-AUC · LGBM 2단계	0.777 (비입양군만)	0.302 (개·고양이 전체)
최종 안락사 전략	2단계	**직접** (CV 차이 -0.011 ± 0.011)
임곗값 결정	학습 데이터 (0.499)	OOF 예측 (0.379)
test Recall / Precision	0.817 / 0.587 (비입양군만)	0.815 / 0.102 (개·고양이 전체)
이름 변수	has_name	has_original_name
계절 변수	검증 없이 포함	제외 (CV 근거)
나이 구간	개·고양이 공통 6구간	종별 4단계
품종 처리	상위 15 + 혼종 (전체 데이터로 선정)	상위 15 (train에서만) + 혼종 + **품종군**
입양 모델 코드	폴더에 없음	비교 · 튜닝 · SHAP 통합 (ROC-AUC 0.783)
교차검증	RepeatedStratifiedKFold	StratifiedGroupKFold
시간 기준 검증	없음	안락사 ROC-AUC 0.865 · 입양 0.742
데이터 경로	개인 PC 절대경로	상대경로 (zip 직접 읽기)

숫자를 읽을 때 주의

Precision이 0.587 → 0.102로 크게 떨어진 것처럼 보이지만, 이는 **평가 집단의 안락사 비율**(비입양군 12% vs 개·고양이 3%)과 **야생동물 제외** 때문입니다. 같은 Recall 0.8에서 무작위로 고르면 Precision은 0.032이므로, 모델은 무작위보다 **약 3배 정확**하게 표시합니다.

SECTION 6

발표자료 수정 가이드

v2 결과를 반영하려면 슬라이드별로 다음을 바꾸는 것을 권장합니다.

슬라이드	현재 내용	수정 제안
3 (문제 정의)	123,566건 병합 · 안락사 8,266건 6.7%	merge_asof 병합 122,960건. 개·고양이 기준 안락사 3.2% 추가
4 (피드백 반영)	나이 7건 삭제 · 폴드 내 SMOTE 등	"병합 오류 694행 교정", "이름 누수 제거", "계절 제외 실험", "시간 기준 검증" 추가
5 (병합)	visit_seq로 오결합 방지	visit_seq의 한계(음수 체류 694행) → merge_asof로 교체한 과정을 보여주기
7 (전처리)	이름 없음이 '예측 핵심 변수'	이름 3종 구분 그래프(그림 1 오른쪽) + "보호소 부여 이름은 누수라 제외"
9 (EDA)	계절 영향 작음	"CV 제외 실험 결과 효과 없음 → 모델에서 제외"로 결론 명시
10~11 (입양)	비입양 Recall 69.2% · 이름 보유 → 입양 ↑	튜닝 LightGBM 수치로 교체 (ROC-AUC 0.783, 비입양 Recall 66.4%) · 그림 3 사용
12~13 (안락사 설계)	직접 vs 2단계	"야생동물 분리" 단계 추가 (그림 1 왼쪽, 표 4.5)
14~15 (모델 선정)	2단계 LGBM 채택 (PR-AUC 0.777)	**공정 비교 결과 직접모델 채택**. 표 4.6과 그림 4 사용, 착시 사례를 교훈으로 제시
16 (안락사 요인)	1위 나이	원래 이름 · 나이 · 건강상태 · 입소 유형 (그림 6). 품종은 인과 아님 강조
17 (운영 지침)	우선순위 = (1-P(입양)) × P(안락사|비입양)	P(입양)과 P(안락사) 두 축으로 분류. "25% 검토 → 안락사 82% 포착"
18 (운영 원칙)	월별 재평가	시간 검증 근거 추가: 같은 임곗값에서 Recall 0.73~0.86 변동

6.1 새로운 운영 분류 제안

	안락사 위험 낮음	**안락사 위험 높음** (상위 25%)
입양 가능성 높음	일반 관리	의료 스크리닝 후 빠른 입양 연계
입양 가능성 낮음	홍보 · 프로필 강화 · 임시보호	**최우선 개입** 의료 · 행동 교정 · 이송 파트너 연계

두 확률을 곱해 한 점수로 만들면 수학적으로 P(안락사)와 거의 같아져 정보가 사라집니다. 두 축으로 나누면 동물별로 **어떤 개입이 필요한지**가 드러납니다.

SECTION 7

남은 한계

한계	설명	대응 방향
품종군 규칙	품종명 키워드로 나눈 근사치. 혼종의 두 번째 품종은 무시	견종 표준 분류표와 매칭
중도 절단	추출 시점(2021-03)에 보호 중인 동물은 제외 → 최근 기간은 빨리 퇴소한 동물 위주	생존분석 · 추출 시점 이후 데이터 확보
외부 검증	오스틴 한 곳의 데이터만 사용	다른 보호소 공개 데이터로 검증
이름 정보의 시점	* 표시로 보호소 부여 여부만 구분. 원래 이름이 입소 후 확인된 경우는 구분 불가	입소 시점 스냅샷 데이터 필요
인과 해석	SHAP · 중요도는 연관성	개입 효과는 실험(A/B)이나 인과추론으로 별도 검증
낮은 Precision	개·고양이 안락사율 3%라 경보 10건 중 1건 적중	스크리닝 용도로 한정 · 비용 기반 임곗값 설계

APPENDIX

부록. 새로 등장한 개념

v2 노트북에서 새로 사용한 기법과 결과를 읽는 데 필요한 개념입니다. (기본 개념은 분석 보고서 부록 A 참고)

데이터 처리

merge_asof

As-of Merge

정확히 같은 키가 아니라 **가장 가까운 시점**으로 두 표를 연결합니다. direction='forward'는 "이후 첫 기록", 'backward'는 "이전 마지막 기록"입니다. by 인자로 같은 그룹(동물) 안에서만 찾게 할 수 있습니다. 양쪽 모두 시간 순으로 정렬되어 있어야 합니다.

이 프로젝트에서 입소 이후 첫 퇴소 연결 → 음수 체류 694행 해소 (§3)

Pipeline · ColumnTransformer

scikit-learn

전처리와 모델을 하나로 묶는 도구입니다. ColumnTransformer는 열마다 다른 전처리(원-핫, 스케일링 등)를 적용하고, Pipeline은 이를 모델과 이어 붙입니다. **fit할 때 전처리도 함께 학습**되므로, 교차검증의 학습 폴드나 train에서만 학습되어 누수가 원천 차단됩니다.

이 프로젝트에서 상위 15개 품종 선정이 train에서만 이뤄짐 (§7)

OneHotEncoder(max_categories)

Infrequent Categories

가장 흔한 범주 N-1개만 따로 열로 만들고 나머지는 '드문 범주' 하나로 묶습니다. 처음 보는 범주가 test에 나와도 handle_unknown='infrequent_if_exist'로 드문 범주에 넣어 오류 없이 처리합니다.

이 프로젝트에서 품종 2,600여 종 · 색상 590여 종 → 각 16개 열

변수 제외 실험

Ablation Study

변수 하나를 넣고 뺀 모델을 **같은 교차검증**으로 비교해 그 변수의 기여를 측정합니다. 차이를 폴드 간 표준편차와 비교하면 우연인지 판단할 수 있습니다.

이 프로젝트에서 계절 효과 +0.0003 < 표준편차 0.003 → 제외 (§8)

검증

StratifiedGroupKFold

Stratified + Group K-Fold

두 조건을 동시에 지키는 교차검증입니다. ① 같은 그룹(동물)은 한 폴드에만 들어가고 ② 각 폴드의 양성 비율이 비슷하게 유지됩니다. 재방문 동물이 있고 양성이 드문 이 데이터에 가장 적합합니다.

이 프로젝트에서 모든 CV에 사용 (§8~11)

OOF 예측

Out-of-Fold Prediction

교차검증에서 각 행을 **그 행을 학습에 쓰지 않은 모델**로 예측한 값입니다. train 전체에 대해 "처음 보는 데이터" 예측을 얻을 수 있어, test를 건드리지 않고 임곗값을 정하거나 전략을 비교할 수 있습니다.

이 프로젝트에서 OOF로 정한 임곗값 0.379 → test Recall 0.815 (§11)

RandomizedSearchCV

Random Search

하이퍼파라미터 조합을 무작위로 N개 뽑아 교차검증으로 평가하고 최고 조합을 고릅니다. 모든 조합을 시도하는 GridSearch보다 빠르면서 비슷한 성능을 냅니다. fit에 groups를 넘기면 그룹 CV로 튜닝합니다.

이 프로젝트에서 12개 조합 × 3폴드로 입양 모델 튜닝 (§9)

시간 기준 검증과 분포 변화

Temporal Validation / Drift

과거로 학습하고 미래로 평가합니다. 시간이 지나면 입소 동물 구성이나 운영 정책이 바뀌어(분포 변화) 같은 모델이라도 성능과 적절한 임곗값이 달라질 수 있습니다.

이 프로젝트에서 2020년 Recall 0.86 vs 2019년 0.73 (§12)

중도 절단 Right Censoring

관찰이 끝난 시점에 결과가 아직 나오지 않은 사례입니다. 이를 빼고 분석하면 최근 기간은 "결과가 빨리 나온" 사례만 남아 편향됩니다.

이 프로젝트에서 2021년 입소 642건은 해석에서 제외

불균형 · 평가

SMOTENC SMOTE for Nominal and Continuous

범주형 변수가 섞인 데이터용 SMOTE입니다. 연속형 변수는 이웃 사이를 보간하고, 범주형 변수는 이웃들의 **가장 흔한 값**을 가져와 0.37 같은 비현실적 값을 만들지 않습니다. 원-핫 **전의** 원본 범주에 적용해야 합니다.

이 프로젝트에서 CV PR-AUC 0.285로 가장 낮아 사용 안 함 (§11)

기준선 대비 배수 Lift over Baseline

PR-AUC나 Precision을 무작위 기준선(양성 비율)으로 나눈 값입니다. 양성 비율이 다른 집단이나 기간을 비교할 때 원래 수치보다 공정합니다.

이 프로젝트에서 PR-AUC 0.332 / 0.032 ≒ 10배, 시간 검증 0.190 / 0.019 ≒ 10배

Precision @ Recall Precision at fixed Recall

목표 Recall(예: 0.8)을 달성하는 임곗값에서의 Precision입니다. "놓치지 않으려면 얼마나 많은 헛경보를 감수해야 하는가"를 한 숫자로 보여줘 운영 판단에 유용합니다.

이 프로젝트에서 LightGBM 직접 0.108 → 경보 10건 중 약 1건 적중

SHAP beeswarm 그림 읽는 법 SHAP Summary Plot

세로축은 중요도 순 변수, 점 하나는 동물 한 마리입니다. 가로 위치는 그 변수가 예측을 얼마나 올렸는지(오른쪽) 내렸는지(왼쪽), 색은 변수 값(빨강=높음, 파랑=낮음)입니다. 빨간 점이 왼쪽에 몰려 있으면 "값이 클수록 확률이 낮아진다"는 뜻입니다.

이 프로젝트에서 입양 모델에서 나이의 빨간 점이 왼쪽 → 고령일수록 입양↓ (그림 3)