

MATRIX 25-2 컨퍼런스 | 2팀 전건우, 이시현, 성소연

목차

01 프로젝트 소개

- 문제 정의
- 프로젝트 목표·피드백 반영

02 데이터 이해 및 전처리

- 입·퇴소 데이터 병합
- Target 설계
- 데이터 전처리

03 Outcome 다중분류

- 다중분류를 통한 전체 Outcome 구조 탐색

04 입양 여부 예측

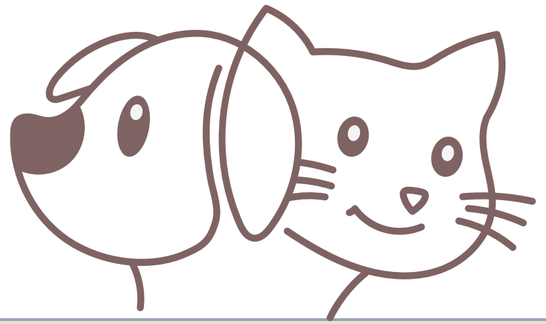
- 입양 관련 EDA
- 모델 선정 및 모델링
- 모델 비교·성능 평가
- SHAP 기반 영향 요인 분석

05 안락사 위험 분석

- 전체 개체 vs 비입양군 모델
- 불균형 대응
- PR 곡선·혼동행렬·해석

06 인사이트 및 운영전략

- 통합 인사이트
- 보호소 운영전략
- 결론



01 문제 정의와 프로젝트 목표

입소 순간부터 시작되는 개입의 골든 타임

123,566 건

병합된 입·퇴소 기록
(Austin Animal Center)

6.7 %

최종 모델링 데이터 기준
안락사 8,266건

122,847 건

결측·이상치 처리 후
최종 모델링 데이터

"데이터로 입양이 어렵고 안락사 위험이 높은 개체를 입소 즉시 선별할 수 있는가?"
프로젝트 목표 : 실무자의 경험을 보조할 데이터 기반 조기 선별 체계 생성

입양 가능성 + 안락사 위험 → 보호소 개입 우선순위 점수

01 기획서 피드백 1:1 반영

교수님 피드백

- ① 이진분류만으로 결과 의미가 뭉개짐
- ② 비입양군 내부 모델만으로 비교가 제한됨
- ③ 이상치·고카디널리티 처리 근거 부족
- ④ 불균형·개체 재방문 누수 대응 필요

반영 내용

- ① 5개 Outcome 탐색 후 목적별 이진 타깃 파생
- ② 전체 직접모델과 비입양군 2단계 모델 비교
- ③ 나이 오류 7건 삭제 + 혼종·다색 변수 파생
- ④ GroupSplit·class_weight·CV·폴드 내 SMOTE

02 입·퇴소 데이터 병합

Intake Data

Animal Type
Intake Type
Intake Condition
Age
Breed / Color
Sex
Sterilized_status

→

Animal ID
+
방문 순서

→

최종분석 데이터

visit_seq 변수를 생성해
동일 ID의 반복 입·퇴소 회차를 매칭하여
입·퇴소 오결합을 방지

←

Outcome Data

Outcome Type
Outcome Date

출처 : Kaggle / Animal Shelter Analytics – Austin Animal Center Intakes & Outcomes

02 타깃 설계

입양 / 비입양으로만 나누면 '비입양' 안의 이송·반환·안락사가 하나로 뭉개진다.
그래서 결과 구조를 먼저 살펴본 뒤, **운영 목적에 맞춰 타깃을 분리**했다.

01 원안

입양 vs 비입양 이진분류

직관적이고 실용적으로 보였던 첫 접근

02 문제 발견

비입양(0)에 반환·이송·안락사·기타가 공존

좋은 결과(반환)와 최악(안락사)이 같은 0으로 묶여 학습 신호가 오염된다

03 재설계

다중분류로 전체 구조 탐색
→ 목적별 이진 타깃 분리

보호소가 실제로 내리는 의사결정 단위에 맞춘 설계

이렇게 나온 두 개의 운영용 타깃

① 입양 가능성

target_adoption · 전체 개체 대상

1차 모델. 어떤 동물이 입양으로 이어지는지를 예측

② 안락사 위험

전체 직접모델 vs 비입양군 2단계 모델 비교

두 접근을 비교해 최적 모델 선정

02 데이터 전처리

원칙 — 불필요한 건 걷어내고, 숨은 신호는 살린다

데이터 누수 차단

누수 차단

× ~~체류기간·Outcome 상세정보를 예측에 활용?~~

✓ 둘다 '퇴소 후에야 확정' → 입소 시점엔 알 수 없음
→ 예측변수에서 제외

나이 이상치

신뢰성 · 표현력

× ~~이상치를 중앙값으로 대체?~~

✓ 음수·30세 초과 7건은 원자료 복구 불가
→ 행 삭제. 나이는 연속형 유지 + 생애단계(새끼·성체·노령) 파생

품종·색 고카디널리티

과적합 통제

× ~~품종 2,619 · 색 594를 그대로 원-핫?~~

✓ 상위 15개로 그룹화 + 혼종·단색·다색 등 의미 있는 상위범주로 파생

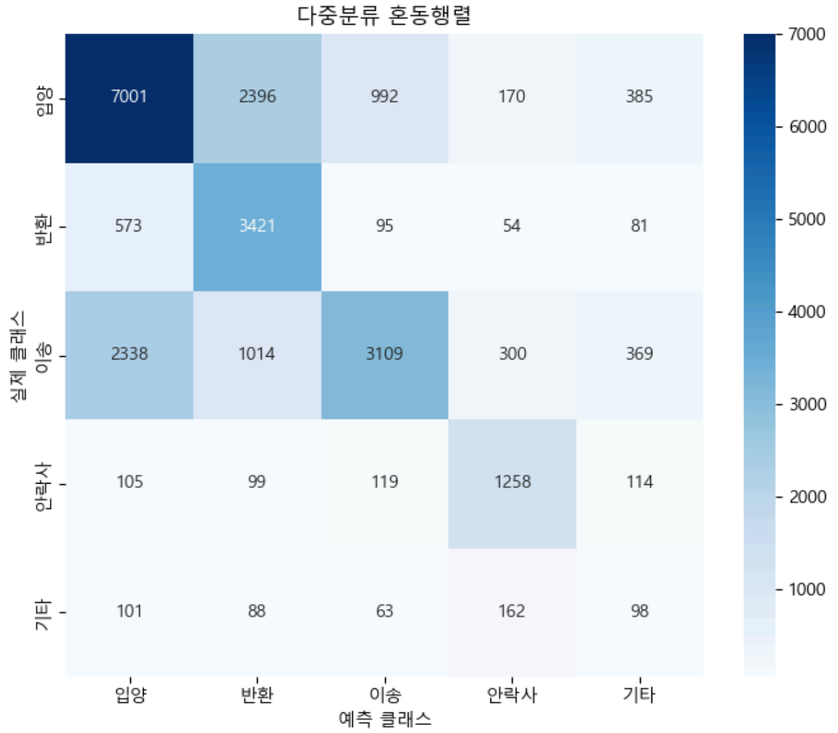
이름 유무

신호 발굴

× ~~이름 결측은 그냥 제거?~~

✓ '이름 없음' 자체가 미등록·취약 신호
→ 'Unknown' 명시 후 has_name 파생 (예측 핵심 변수)

03 다중분류를 통한 전체 Outcome 구조 탐색



LightGBM

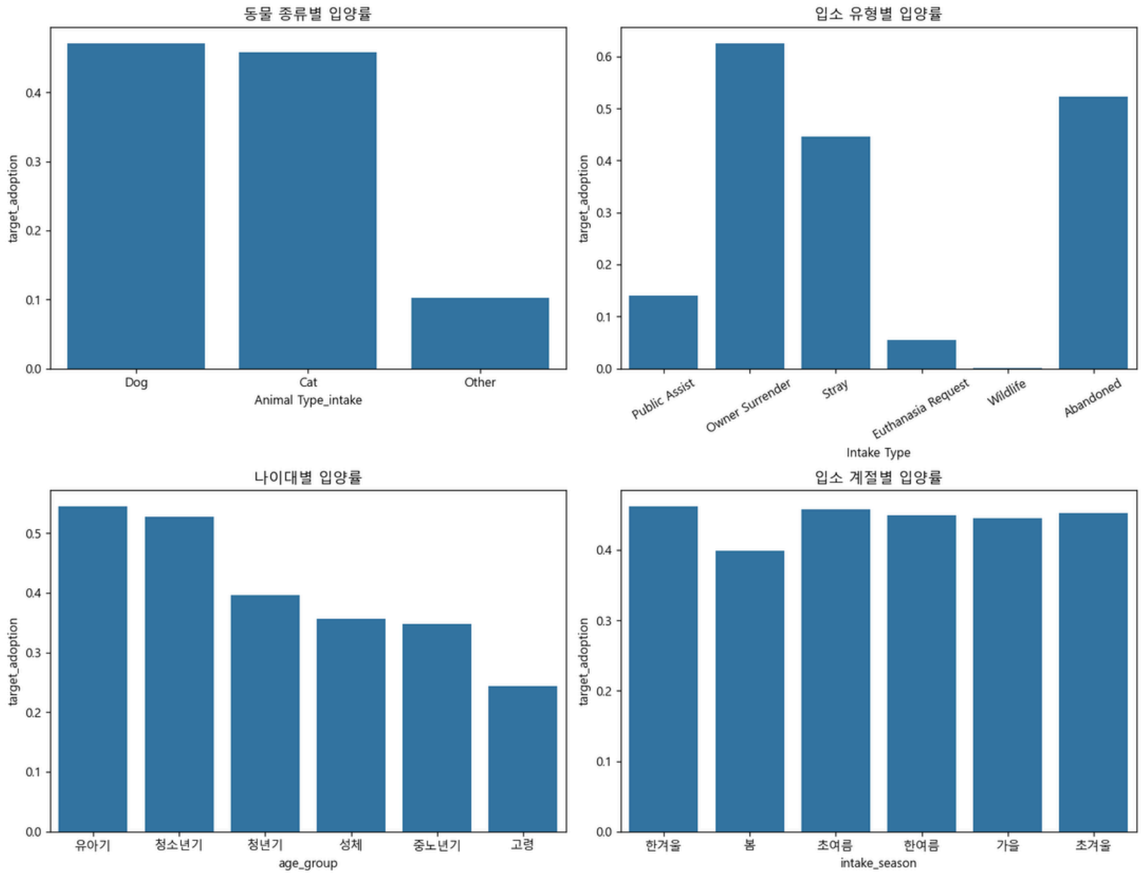
- Accuracy 0.608
- Balanced Accuracy 0.564
- 기타 F1 0.13

- 입양·반환·안락사는 상대적으로 구분되는 패턴 확인
- 이송은 입양·반환과 혼동이 비교적 크게 발생
- 기타 클래스는 F1 0.13으로 구분 한계 확인

Outcome별 특성이 상이함을 확인

→ 운영 목적에 따라 '입양 여부'와 '안락사 여부'를 별도 이진분류로 심화 분석 진행

04 EDA



- 입소 유형별 입양률 차이가 뚜렷

  → '소유자 인계'는 높은 반면 '안락사요청', '야생동물'은 매우 낮음

- 연령 증가에 따라 입양률이 전반적으로 감소

  → 고령 개체일수록 입양 취약 경향 확인

- 동물 종류에 따른 입양률 차이 존재

  → 개, 고양이 대비 기타 동물의 입양률이 현저히 낮음

- 계절에 따른 입양률 차이는 상대적으로 제한적

  → 다른 특성에 비해 계절의 영향은 크지 않은 것으로 관찰

- 입양 개체의 체류기간이 비입양 개체보다 길게 나타남

  → 입양까지 일정 보호기간이 소요되는 경향 확인

04 입양 여부 이진분류 모델링

Logistic Regression·Random Forest·LightGBM을 비교했다.

→ 비선형 상호작용 학습, 고차원 범주형 처리, SHAP 해석 가능성을 종합해 LightGBM을 입양 모델로 선정

Train Data

↓

LightGBM 초기 모델 학습

↓

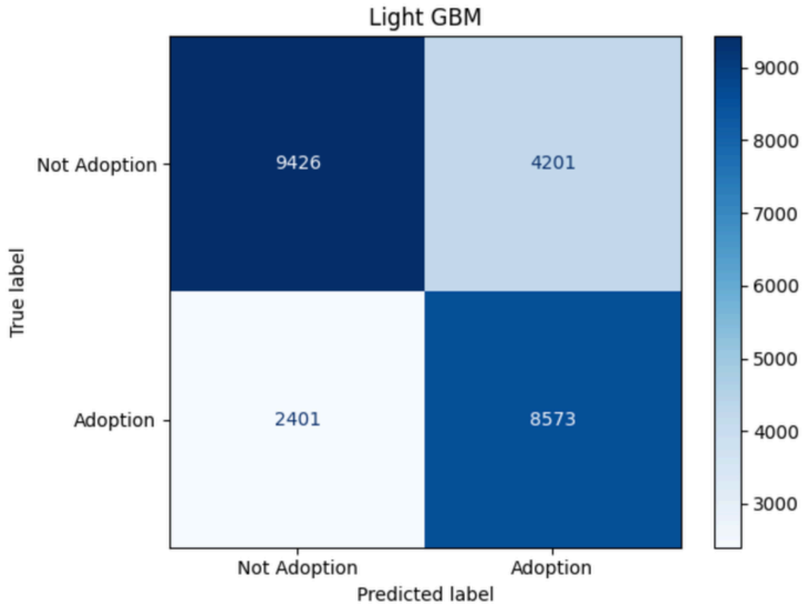
하이퍼파라미터튜닝

↓

Animal ID Group Split Validation

↓

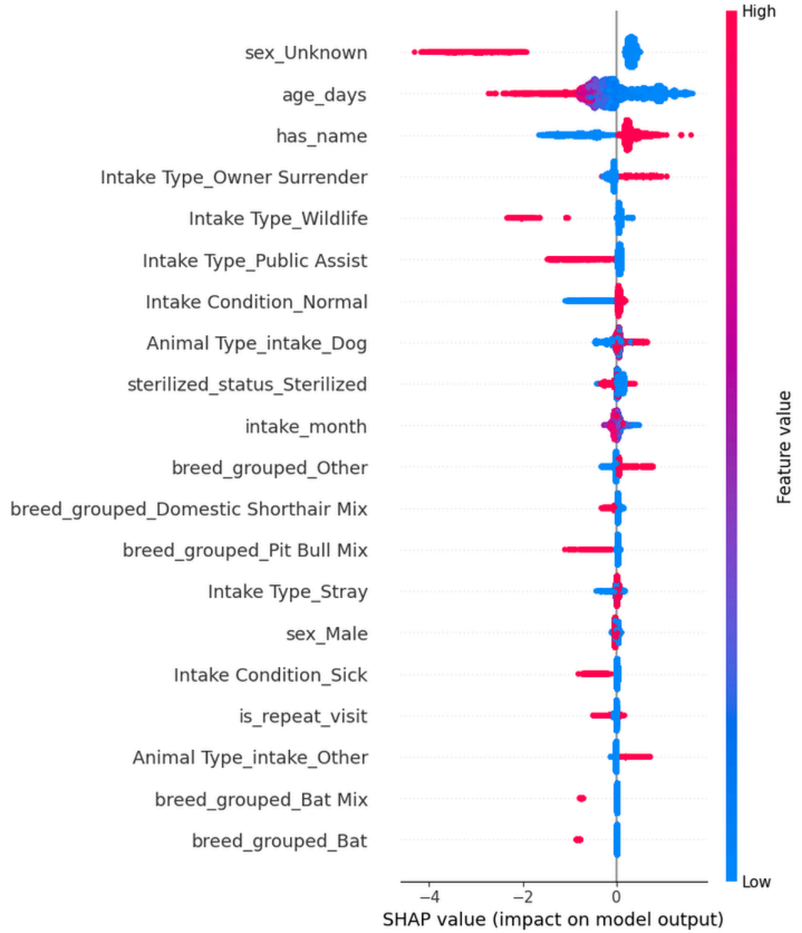
Final LightGBM



- 실제 비입양 개체의 69.2%를 사전 식별
- 비입양 예측 개체의 79.7%가 실제 비입양

※ 별도 입양 모델 테스트셋 기준

04 입양 예측 주요 기여 요인 분석



- 성별 미확인
  → 입양 예측값 크게 감소 → 입소 초기 개체정보 확보 강화
- 고연령
  → 입양 예측값 감소 → 고령동물 맞춤 입양 지원
- 이름 보유
  → 입양 예측값 증가 → 개체 프로필·홍보 강화
- 입소 유형
  → 유형별 입양 예측값 차이 → 입소 유형별 차별화된 관리 전략
- 계절, 성별(M/F) 등
  → 상대적으로 영향 작음

05 안락사 위험 분석

입양이 어려운 동물 중, 누구에게 먼저 개입해야 하는가?

입양 가능성(1차)을 확인했다면, 이제 어떤 동물이 안락사 위험에 처하는지를 예측한다.

직접 vs 2단계

두 접근법 비교

전체 개체 직접 모델 vs
비입양군 2단계 모델

3가지 전략

불균형 대응

class_weight · 임곗값 조정
· 폴드 내 SMOTE

Recall · PR-AUC

평가 지표 전환

위험군을 놓치지 않는 것이
최우선인 두 핵심 지표

05 검증 설계와 불균형 대응

결과의 신뢰성을 담보하기 위해, 결과를 보기 전에 검증 장치를 먼저 설계했다.

누수 차단

Data Leakage 방지

- **Animal ID GroupSplit**

  같은 개체가 train/test에 동시 등장 방지

- **Train / Test 중복 0건**

  개체 단위 완전 분리 확인

불균형 대응

Imbalance Handling

- **Recall · PR-AUC 중심 평가**

  정확도 대신 소수 클래스 지표 우선

- **3가지 전략 CV 검증**

  class_weight · 임곗값 · 폴드 내 SMOTE

해석 원칙

Interpretation

- ✓ **최종 성능 vs 실험 구분**

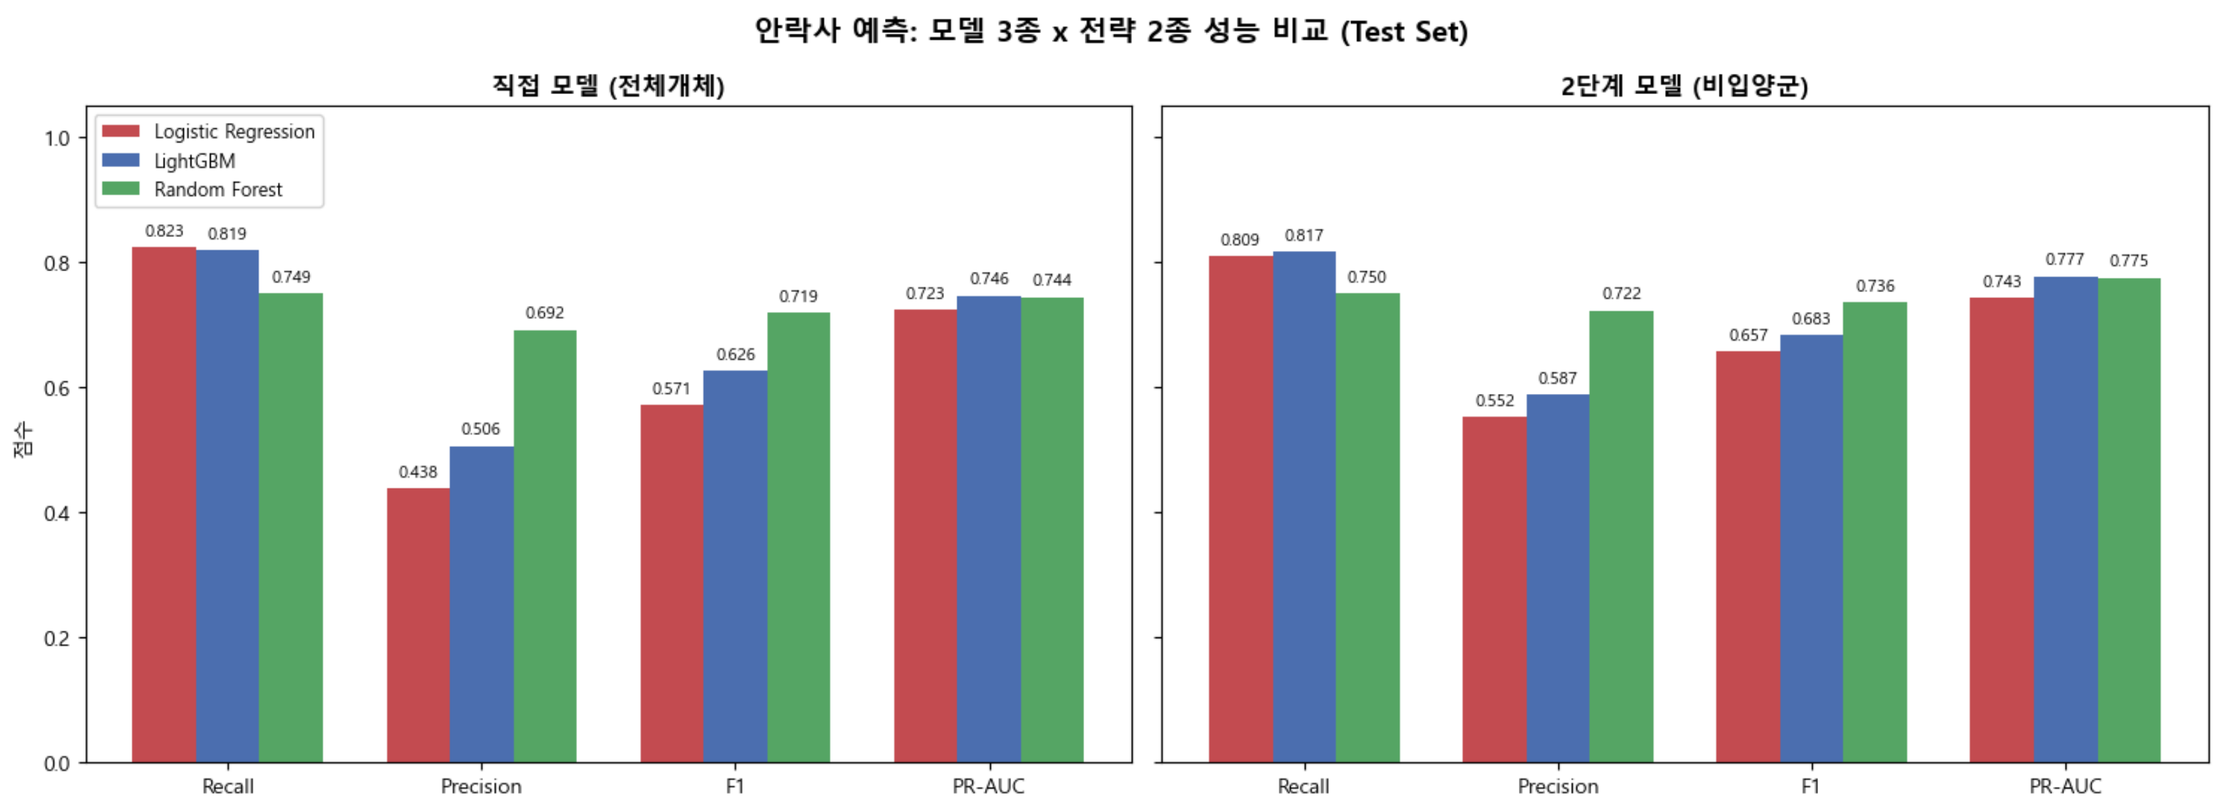
  LGBM 확정 결과와 baseline 비교 분리

- ✓ **임곗값은 별도 검증 후 적용**

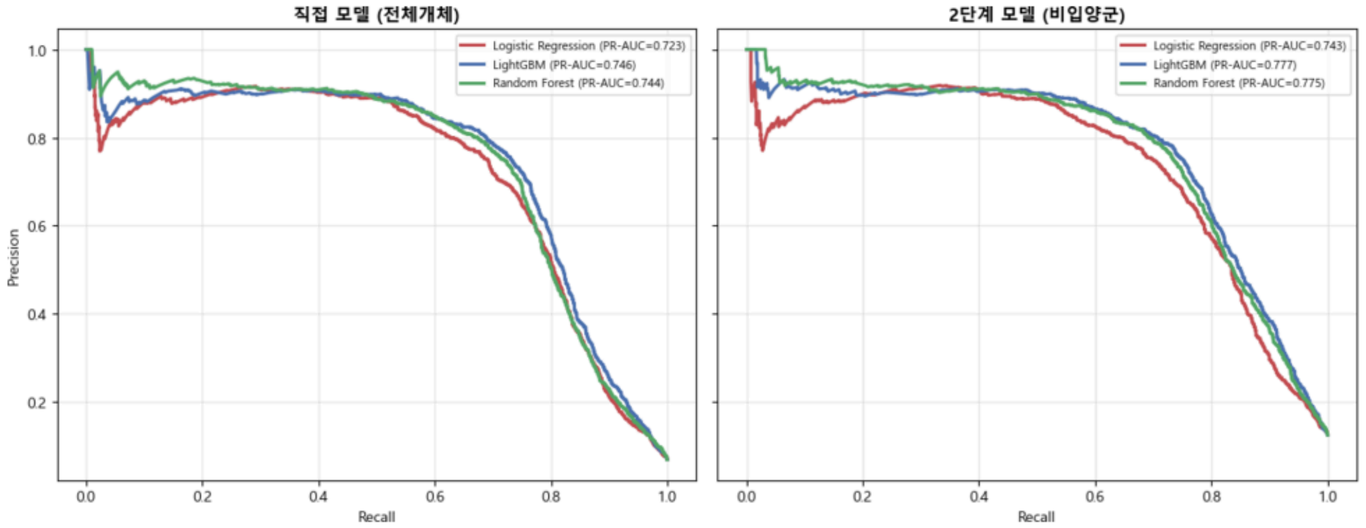
  과적합 방지를 위한 독립 평가

→ **모델·전략별 검증 결과를 명확히 구분해 해석 — 성능 수치의 신뢰성 확보**

05 모델마다 강점 지표가 달랐다



05 PR 곡선과 혼동행렬로 최종 모델 선정

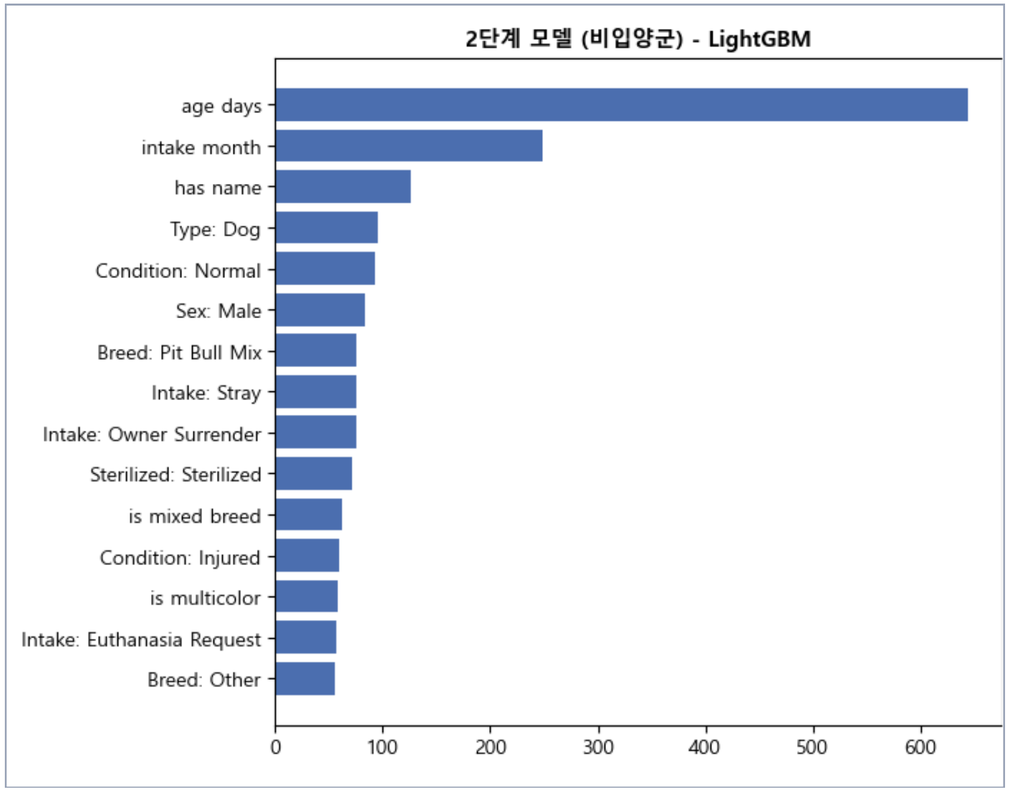




직접모델 LGBM: Recall 0.819 · PR-AUC 0.746
비입양군 LGBM: Recall 0.817 · PR-AUC 0.777

→ 비입양군 2단계 LightGBM 최종 채택
PR-AUC 우위 + 실제 보호소 운영 흐름과 일치

05 안락사 위험을 가르는 핵심 변수



1위 나이 (age_days)

가장 강력한 안락사 위험 신호

2~4위 입소 시점 · 이름 유무 · 건강상태

⚠ 해석 주의

품종·색상 중요도는 연관성일 뿐,
인과효과를 의미하지 않는다

입양 vs 안락사 비교

두 모델 모두 **나이**가 핵심이나, 안락사는 **건강상태(부상·질병)**가 추가로 부각

고령·고위험 개체를 입소 즉시 선별해 집중 관리

06 최종 모델 선정과 보호소 운영 지침

입양 모델 | LightGBM
비선형 상호작용·고차원 범주형 처리·SHAP 설명 가능성

안락사 모델 | 비입양군 LightGBM
Recall 0.817 · PR-AUC 0.777 — 미탐지 비용을 고려해 선별력과 순위화 성능을 우선

우선순위 = (1 − P(입양)) × P(안락사 | 비입양)

① 저입양군 : 홍보·상담·의료 지원
② 고위험군 : 의료·행동·임시보호
③ 직원 판단 보조로 활용하고 월별 Recall·PR-AUC·오탐/미탐 모니터링

※ 2단계 지표는 실제 비입양군 조건부 평가 : 통합 재현·시간/외부 검증은 향후 과제

06 보호소 운영 및 개입 프로세스 (결론)

⚠ 개입 프로세스

1. 입소 즉시 예측

P(입양) · P(안락사 | 비입양) 산출

2. 우선순위 분류

(1−P(입양)) × P(안락사 | 비입양)로 상·중·하 등급화

3. 위험요인별 맞춤 개입

고령	→ 입양 프로그램·임시보호
건강 문제	→ 입소 시 의료 스크리닝
이름 없음	→ 프로필·이름 부여·홍보

운영 원칙

→ 고위험군 우선

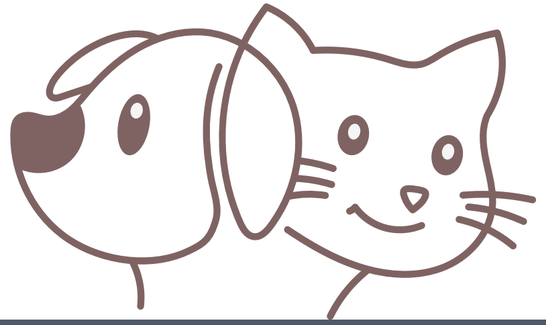
낮은 입양 가능성 × 높은 안락사 위험

→ 직원 검토 필수

모델은 보조 도구 · 자동 처분 결정 금지

→ 월별 재평가

Recall · PR-AUC · 오탐/미탐 · 입양률 점검



Q&A

경청해 주셔서 감사합니다.